

Università degli Studi di Camerino

SCUOLA DI SCIENZE E TECNOLOGIE Corso di Laurea in Informatica (Classe L-31)

	٠ .	1 .	1.		1	C	• 1			T
•	omni	19710110	α	1110	linguaggio	tiin	71011	$1 \cap 1$	n	277
•		iazione	uı	un	meuaeeio	TUH	LZIUIIA.		11	j a v a
_	-				000					

Laureando Massimo Pavoni Relatore **Prof. Luca Padovani**

Matricola 124377

Indice

1	Intr	roduzione	1
	1.1	Motivazione	1
	1.2	Obiettivi	1
	1.3	Struttura della tesi	1
2	Fun	ıx	3
	2.1	Linguaggi funzionali	3
		2.1.1 ML, Haskell e Funx	4
	2.2	Sintassi	5
		2.2.1 Zucchero sintattico	6
3	Infe	erenza di tipo	9
	3.1	Sistemi di tipo	9
		3.1.1 λ-cubo	11
		3.1.2 Sistema FC	12
	3.2	Inferenza secondo Hindley–Milner	14
4	Jav	\mathbf{a}	17
	4.1	Interfacce funzionali	17
	4.2	Operatore ternario	19
	4.3	Tipi generici	20
5	Cor	npilatore	21
	5.1	ANTLR	22
		5.1.1 Analisi lessicale	22
		5.1.2 Analisi sintattica	24
	5.2	Albero sintattico astratto	26
		5.2.1 Gerarchia delle classi	26
		5.2.2 AST builder	28
	5.3	Motore inferenziale	31
			31
		5.3.2 Inferenza su espressioni	34
	5.4		37
		5.4.1 Membri statici	37
		5.4.2 Stack dei contesti	38

		5.4.3 Dichiarazioni monomorfe	39 41
		5.4.5 Type casting "selvaggio"	44
6	Con	clusioni	47
Bi	bliog	rafia	49
	, D1108	, and	10
H	Cle	nco dei codici	
	2.1	Esempio di programma	8
	2.1	Esemplo di programma	C
	4.1	Semplice funzione in Funx	17
	4.2	Corrispondente metodo in Java	17
	4.3	Interfaccia funzionale per espressioni let	18
	4.4	Espressione let in Funx	18
	4.5	Corrispondente classe anonima in Java	18
	4.6	If e operatori booleani in Funx	19
	4.7	Corrispondenti operatori ternari in Java	19
	4.8	Scrittura e utilizzo di funzioni polimorfe in Funx	20
	4.9	Corrispondenti proprietà e metodi Java	20
	5.1	Alcuni token del lexer	23
	5.2	Grammatica per il parser	25
	5.3	Esempio di classe della gerarchia dell'AST	27
	5.4	Parte del codice di PreludeFunction	28
	5.5	Metodi per astrazioni annidate e operatori simbolici binari	29
	5.6	Alcuni metodi visit di ASTBuilder	29
	5.7	Programma in Funx	30
	5.8	Esempio di sottoclasse di Type	32
	5.9	Interfacce utili nel sistema HM	33
	5.10	Altre classi del sistema HM	33
	5.11	Metodo di inferenza per espressioni let	35
		Esempio di inferenza	36
	5.13	Prime aggiunte alla stringa Java	37
		Corrispondente codice Java generato	37
		Struttura e metodi per lo scope	38
	5.16	Aggiunta di contesto per modulo, lambda astrazioni e let	38
		Traduzione di funzioni monomorfe	39
	5.18	Traduzione di funzioni monomorfe in let	40
	5.19	Metodo visit per le dichiarazioni	41
		Metodo visit per le variabili	42
		Metodo di istanziazione con <i>cast</i>	42

Grammatica del lambda calcolo
Grammatica dei famoda carcolo
Grammatica di Funx
Alcuni linguaggi e loro sistemi di tipo
λ-cubo
Grammatica del sistema di tipo di Funx
Definizioni di contesto e variabili libere
Regole di inferenza del sistema HM in Funx
Algoritmo \mathcal{W}
Funzione \mathcal{U}
Possibili comandi e opzioni della <i>CLI</i>
Diagramma semplificato delle classi dell'AST
Oggetto AST in <i>debug</i> e visualizzazione dell'albero
Esempio di errore in Java dovuto a tipi generici
Diagramma semplificato delle classi del $sistema~HM~\dots$
AST con annotazioni di tipo
enco delle tabelle

1. Introduzione

1.1 Motivazione

I linguaggi di programmazione più diffusi non sempre possono essere classificati solamente come procedurali, ad oggetti, logici o funzionali: soprattutto con la diffusione di linguaggi funzionali nell'industria e il progresso della tecnologia per l'esecuzione di algoritmi paralleli, l'introduzione di nuove feature ispirate dalla programmazione funzionale è ben gradita dalla maggior parte degli sviluppatori.

Molti linguaggi moderni possono più opportunamente essere chiamati "ibridi" o "multi-paradigma", in virtù della combinazione di diverse metodologie.

Java nello specifico, a partire dalla versione 8, è stato arricchito con nuovi strumenti e costrutti che permettono di scrivere codice più conciso e dichiarativo: la domanda che ci si pone è quindi se sia possibile tradurre un linguaggio funzionale in codice imperativo, sfruttando le nuove funzionalità così come la programmazione ad oggetti.

1.2 Obiettivi

Il progetto di cui questo documento è relazione ha come obiettivo principale la pianificazione e costruzione di un compilatore da codice sorgente funzionale a codice Java, con particolare attenzione alla semplicità di traduzione data dalle varie feature impiegate.

Il linguaggio dovrebbe essere sufficientemente espressivo da permettere la definizione di funzioni basilari e l'uso della ricorsione; le performance di compilazione ed esecuzione non sono aspetti prioritari, ma devono essere tali da consentire l'utilizzo pratico con fini educativi e dimostrativi.

1.3 Struttura della tesi

Al fine di offrire un quadro completo dello studio effettuato e del progetto, esplorando aspetti sia teorici che pratici, la tesi è suddivisa nei seguenti capitoli:

- 2. introduzione al paradigma funzionale e panoramica generale del linguaggio creato;
- 3. nozioni sui sistemi di tipo per linguaggi funzionali, sistema adottato e inferenza;
- 4. elenco di caratteristiche di Java utili e primi esempi di traduzione;
- 5. descrizione del software realizzato, dettagli d'implementazione e ulteriori esempi;
- 6. conclusioni, risultati ottenuti, osservazioni finali e possibili sviluppi futuri.

2. Funx

Questo capitolo descrive brevemente i linguaggi funzionali e le scelte effettuate durante l'ideazione del linguaggio usato per il progetto: **Funx**.

Il nome nasce dall'unione dei due termini anglosassoni functional e expression; viene quindi pronunciato ['fʌnɪk's] in inglese, [fan-èks] o [fan-ìks] in italiano.

2.1 Linguaggi funzionali

Nonostante i linguaggi di programmazione non si possano confinare all'interno di un solo paradigma, parlando di linguaggi di programmazione si fa comunque spesso riferimento a due grandi categorie: linguaggi imperativi e linguaggi dichiarativi.

I primi hanno caratteristiche direttamente legate al modello di calcolo di *John Von Neumann*, a sua volta non dissimile dalla macchina di *Alan Turing*. Questi linguaggi sono usati per scrivere codice che segue una precisa sequenza di istruzioni, la quale descrive più o meno esplicitamente i passi necessari per risolvere il problema affrontato. Appartengono alla famiglia dei linguaggi di programmazione imperativi sia linguaggi procedurali come Fortran, Cobol e Zig, sia i linguaggi orientati agli oggetti, tra cui Kotlin, C# e Ruby.

I linguaggi dichiarativi, invece, sono fondamentali per lo scopo del progetto: tali linguaggi sono generalmente di altissimo livello e permettono allo sviluppatore di concentrarsi sull'obiettivo da raggiungere piuttosto che sui dettagli implementativi.

Fanno parte di questa categoria linguaggi di interrogazione come SQL, linguaggi logici come Prolog e soprattutto i linguaggi funzionali: Lisp, Clojure, Elixir, OCaml e Haskell sono alcuni esempi.

Alla base di ogni linguaggio funzionale vi è il **lambda calcolo**¹: un sistema formale definito dal matematico *Alonzo Church* (supervisore di *Alan Turing* durante il dottorato), equivalente alla macchina di Turing, ma fondato sulle funzioni pure.

¹«A Set of Postulates for the Fundation of Logic» [Chu32] and «A Set of Postulates for the Foundation of Logic» (Second paper) [Chu33]

La grammatica del lambda calcolo verrà presentata poco più avanti (sezione 2.2), ma le regole che ne governano il funzionamento e il modo in cui queste vengano utilizzate per ridurre le espressioni ad una forma normale esulano dai fini di questo documento. Rimane comunque rilevante elencare le principali qualità che un linguaggio funzionale usualmente matura grazie al lambda calcolo:

- funzioni come entità di prima classe: le funzioni possono essere passate come argomenti e restituite come risultato di altre funzioni;
- immutabilità: le variabili utilizzate sono immutabili;
- purezza: le funzioni sono libere da effetti collaterali (non modificano lo stato del programma) e restituiscono sempre lo stesso output per input identici;
- ricorsione: la ricorsione è il meccanismo più idiomatico per esprimere l'iterazione su una struttura dati.

2.1.1 ML, Haskell e Funx

Nonostante le funzioni pure tipiche di un linguaggio funzionale siano un concetto molto attraente dal punto di vista della correttezza della computazione, i vincoli così imposti possono risultare stringenti a tal punto da rendere difficile, se non impossibile, la scrittura di programmi che interagiscano con il mondo reale.

Per questo motivo, molti linguaggi funzionali permettono invece di utilizzare particolari funzioni impure o di effettuare almeno operazioni di input/output. Inoltre, molti linguaggi prevalentemente imperativi adottano ormai da tempo alcune caratteristiche tipiche dei linguaggi funzionali (e.g. Rust, il linguaggio più amato² dagli sviluppatori secondo i sondaggi di *Stack Overflow*, eredita molto dal linguaggio con cui era scritto il suo primo compilatore, OCaml, ed è dotato quindi di funzioni di prima classe, immutabilità di default, strutture dati algebriche, ecc.).

ML è un linguaggio funzionale sviluppato negli anni '70 presso l'Università di Edimburgo, costituente la base per moltissimi dei linguaggi sviluppati in seguito. ML permette effettivamente l'uso di funzioni impure, ma fra i suoi discendenti vi è Haskell, uno dei pochi linguaggi invece completamente puri.

 ${\tt Haskell}$ si avvale di un pattern di programmazione chiamato $monadi^3$ per gestire le operazioni di input/output e altre operazioni impure, mantenendo le funzioni pure.

Nell'ideare **Funx** l'ispirazione viene proprio da Haskell, ma è presente la possibilità di dichiarare un'unica funzione impura (il cosiddetto *main*) per permettere di visualizzare a schermo un risultato. Il linguaggio non è quindi allo stesso livello di purezza di Haskell, e naturalmente non supporta molte delle funzionalità più avanzate di quest'ultimo (come le *classi di tipi* e il *pattern matching*), ma ne mutua altre comunque interessanti, tra cui l'uso di alcuni operatori infissi e il *polimorfismo parametrico*.

 $^{^2}$ Stack Overflow Developer Survey 2023 (https://survey.stackoverflow.co/2023), Rust is the most admired language

³ «Notions of Computation and Monads» [Mog91]

2.2 Sintassi

La sintassi di **Funx** risulta molto simile a quella di Haskell, con poche differenze dovute a tre principali motivi:

- libera scelta di nomi e simboli per le parole chiave;
- necessità di successiva traduzione in Java;
- difficoltà e scarso valore all'interno del progetto dell'implementazione di un parser dipendente dall'indentazione.

A prescindere da ciò, il cuore del linguaggio è lo stesso di ogni altro linguaggio derivato dal lambda calcolo: la sua definizione si può agilmente comprendere visualizzando la grammatica del lambda calcolo e confrontandola con quella (leggermente semplificata) di **Funx**, facendo attenzione alle regole aggiuntive.

Figura 2.1: Grammatica del lambda calcolo

Le tre regole in Figura 2.1 indicano le tre componenti indispensabili del lambda calcolo:

- variabile: simbolo rappresentante un parametro;
- applicazione: applicazione di funzione ad un argomento (entrambi espressioni);
- astrazione: definizione di una funzione anonima, con un solo input x (variabile vincolata) e un solo output E (espressione); per definire funzioni con più parametri si debbono usare molteplici astrazioni annidate (tecnica detta currying).

```
Modulo
                  M
                              nome \cdot L
                              ?(schema\ di\ tipo) \cdot id = E
                  D
Dichiarazione
                                                                    funzione
                  E
Espressione
                                                                    costante
                              x
                                                                    variabile
                              E_l E_r
                                                                    applicazione
                              \lambda x \cdot E
                                                                    astrazione
                              L
                                                                   let
                              if E_c then E_t else E_e
                                                                    if
                              let \cdot D (\cdot D)^* \cdot in E
                  L
Let
```

Figura 2.2: Grammatica di Funx

È facile constatare la presenza delle ulteriori produzioni per la definizione del modulo corrente (informazione inclusa a prescindere dal fatto che il linguaggio ad ora non supporti l'importazione di moduli esterni che non siano la libreria standard) e di funzioni con nome: lo schema di tipo è un'informazione opzionale relativa al tipo della funzione e di cui si parlerà più approfonditamente nella sezione 3.1.2.

Per quanto riguarda invece le espressioni, vengono introdotte tre nuove regole:

- costante: rappresenta un valore letterale, come un numero o una stringa;
- let: permette di avere dichiarazioni locali utilizzabili all'interno di un'espressione;
- if: la più classica istruzione condizionale controllata da un'espressione booleana.

2.2.1 Zucchero sintattico

Con lo scopo di rendere il codice più leggibile, conciso e semplice, **Funx** introduce dello zucchero sintattico (del tutto simile a quello di Haskell). In Tabella 2.1 sono riportati l'indispensabile per evitare il parsing dell'indentazione, le semplificazioni comuni utili all'arrichimento del lambda calcolo, e infine tutti gli operatori simbolici supportati al momento (assieme alla notazione per indicarne associatività e precedenza).

Zucchero		Sostituzione
/x -> e		λ x . e
\x y -> e		λ x . λ y . e
f x y = e		$f = \lambda x \cdot \lambda y \cdot e$
let		
f1 = e1		let $f1 = e1 \cdot f2 = e2$ in $e3$
f2 = e2		
in e3		
f3 = e3		
with		
f1 = e1		$f3 = let f1 = e1 \cdot f2 = e2 in e3$
f2 = e2		
out		
main = e3		
f1 = e1		main = let f1 = e1 \cdot f2 = e2 in e3
f2 = e2		
if b then el	else e2 fi	if b then e1 else e2
e1 . e2	infixr 9	compose e1 e2
e1 / e2	infixl 7	divide e1 e2
e1 % e2	infixl 7	modulo e1 e2
e1 * e2	infixl 7	multiply e1 e2
e1 + e2	infixl 6	add e1 e2
e1 - e2	infixl 6	subtract e1 e2
e1 > e2	infix 4	greaterThan e1 e2
e1 >= e2	infix 4	greaterThanEquals e1 e2
e1 < e2	infix 4	lessThan e1 e2
e1 <= e2	infix 4	lessThanEquals e1 e2
e1 == e2	infix 4	equalsEquals e1 e2
e1 != e2	infix 4	notEquals e1 e2
!!e	prefix 4	not e
e1 && e2	infixr 3	if e1 then e2 else False
e1 e2	infixr 2	if e1 then True else e2
e1 \$ e2	infixr 0	apply e1 e2

Tabella 2.1: Zucchero sintattico

Come già accennato, il Capitolo 5 illustrerà come l'albero sintattico astratto (AST) di un programma viene ottenuto, annotato e tradotto in Java; la sezione 4.2 esporrà invece il motivo della traduzione degli operatori booleani binari in if.

Alcuni esempi di funzioni sono presentati nel Codice 2.1; seppur superflua, l'indentazione è inclusa per maggiore chiarezza.

```
main = factorial 20
1
2
   factorial : Int -> Int
3
   factorial n = if n == 0 then 1 else n \star factorial (n - 1) fi
5
   even : Int -> Bool
6
   even = let
8
         even1 : Int -> Bool
         even1 n = if n == 0 then True else odd (n - 1) fi
9
10
11
         odd : Int -> Bool
         odd n = if n == 0 then False else even1 (n - 1) fi
12
13
      in even1
14
   gcd : Int -> Int -> Int
15
   gcd a b = if b == 0 then a else gcd b (a % b) fi
16
17
   xor : Bool -> Bool -> Bool
18
   xor a b = (a || b) && !!(a && b)
```

Codice 2.1: Esempio di programma

3. Inferenza di tipo

Dopo aver discusso la sintassi di **Funx**, è importante far notare come i programmi non abbiano bisogno di annotazioni di tipo, nonostante siano stati adottati tipi statici. In questo capitolo affronteremo l'argomento dei sistemi di tipo e dell'inferenza, meccanismo proprio di molti linguaggi, funzionali e non, che rende possibile la deduzione automatica del tipo di un termine basandosi sull'utilizzo delle variabili e delle funzioni.

3.1 Sistemi di tipo

Durante la genesi di ogni linguaggio di programmazione, una delle scelte più significative riguarda l'introduzione di un sistema per gestire i tipi di variabili ed espressioni. Tali sistemi di tipo sono di fatto insiemi di regole logiche che permettono di assegnare una proprietà "type" a ciascuno dei termini del linguaggio che ne necessitano. Sono principalmente suddivisi in due categorie:

- tipizzazione statica: i tipi sono definiti a tempo di compilazione e non possono cambiare mentre il programma è in esecuzione;
- tipizzazione dinamica: i tipi vengono stabiliti durante l'esecuzione e possono cambiare in qualsiasi momento.

Oltre a questa distinzione esistono varie sfumature e approcci differenti, informalmente classificati in base alla rigidità delle regole di tipizzazione. Si parla di tipizzazione debole quando ad esempio sono consentite conversioni implicite tra tipi diversi, tipizzazione forte se sono impedite, oppure qualora sia o meno disponibile l'aritmetica dei puntatori.

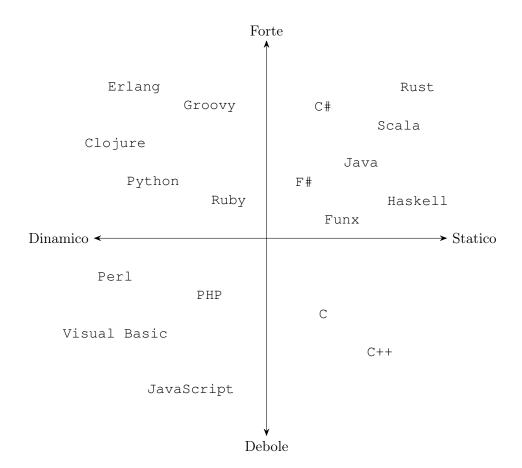


Figura 3.1: Alcuni linguaggi e loro sistemi di tipo

Grazie ai tipi dinamici, linguaggi quali Python e JavaScript permettono veloce prototipazione, flessibilità e codice più conciso, a discapito però di una più alta probabilità di incontrare errori importanti a runtime, piuttosto che in fase di compilazione.

Al contrario, i tipi statici spesso migliorano naturalmente la mantenibilità di un progetto: viene limitata la possibilità di scorciatoie nello sviluppo, ma si hanno maggiori garanzie di correttezza, in quanto il compilatore può implementare ulteriori controlli e segnalare errori semantici più precisi già prima dell'esecuzione del programma.

D'altro canto, l'obbligo di specificare i tipi di ogni variabile, oggetto, funzione e parametro può risultare tedioso e talvolta ridondante; molti linguaggi moderni, tra cui Haskell, ovviano a quest'inconvenienza tramite l'uso dell'inferenza di tipo.

Gli algoritmi di inferenza introducono numerosi benefici, in particolare:

- la scrittura del codice è meno onerosa per lo sviluppatore a prescindere dal sistema di tipi utilizzato, e diviene quindi estremamente vantaggioso utilizzare tipi statici;
- le annotazioni ora opzionali possono essere aggiunte dal programmatore quando vi sono casi difficili da disambiguare automaticamente, oppure per migliorare la leggibilità del codice;
- gli strumenti di sviluppo per il linguaggio possono sfruttare informazioni fornite dal motore inferenziale per suggerire il tipo delle espressioni e arricchire i messaggi di errore e di warning.

3.1.1 λ-cubo

Al fine di comprendere quale sistema il linguaggio **Funx** implementi, prima di discutere l'inferenza si vuol descrivere brevemente il λ -cubo, lambda cubo¹, un modello introdotto per classificare i sistemi di tipo applicabili al lambda calcolo.

In Figura 3.2 è possibile osservare come la struttura del cubo abbia all'origine il lamb-da calcolo semplicemente tipato $(\lambda \rightarrow)$ e come le tre dimensioni in cui si sviluppa rappresentino ciascuna un'estensione del sistema:

- tipi dipendenti (→): la definizione dei tipi può dipendere dai valori delle variabili (implementati da linguaggi funzionali come Agda, Coq e Idris);
- polimorfismo parametrico (†): i tipi possono essere polimorfi, generalizzati tramite variabili di tipo (presenti nei sistemi adottati da ML, OCaml e Haskell);
- **costruttori** di **tipo** (\nearrow): capacità di costruire nuovi tipi a partire da tipi esistenti (Haskell ne fa grande uso poiché ogni nuovo tipo, dichiarato con la keyword data, è un nuovo costruttore di tipo).

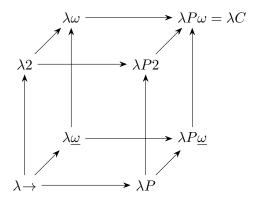


Figura 3.2: λ-cubo

Senza entrare troppo nei dettagli, in ordine crescente di potenza espressiva:

- $\lambda \rightarrow (lambda\ calcolo\ semplicemente\ tipato)$: tipi monomorfi;
- $\lambda \underline{\omega}$ (lambda weak omega): costruttori di tipo;
- λ2 (lambda due, lambda F, lambda calcolo polimorfico): polimorfismo parametrico;
- λP (lambda P): tipi dipendenti;
- $\lambda P\underline{\omega}$ (lambda P weak omega): costruttori di tipo e tipi dipendenti;
- $\lambda\omega$ (lambda omega): costruttori di tipo e polimorfismo parametrico;
- $\lambda P2$ (lambda P due): polimorfismo parametrico e tipi dipendenti;
- $\lambda P\omega = \lambda C$ (lambda P omega, lambda C, calcolo delle costruzioni): combinazione di tutte le tre estensioni.

¹ «Introduction to generalized type systems» [Bar91]

3.1.2 Sistema FC

Tra i vari sistemi di tipo per il lambda calcolo, uno dei più interessanti è lambda F (vertice $\lambda 2$ in Figura 3.2) poiché molto utile per la generalizzazione delle funzioni: un problema molto ricorrente nella programmazione con qualsiasi linguaggio è infatti la duplicazione di codice per funzioni che svolgono operazioni simili su tipi diversi.

Il sistema F risolve tale problema introducendo il **polimorfismo parametrico** e di conseguenza la distinzione tra tipi monomorfi (monotipi) e tipi polimorfi (politipi).

I tipi delle funzioni possono essere caratterizzati tramite quantificatori universali e variabili di tipo ove sia necessario un tipo generico (spesso vengono usate singole lettere dell'alfabeto greco o latino).

Tuttavia, $\lambda 2$ nella sua forma più pura, oltre a non essere un sistema Turing-completo (è possibile definire solamente la ricorsione primitiva), rende l'inferenza di tipo trattata nella sezione 3.2 un problema non decidibile².

Pertanto, il linguaggio Haskell non implementa semplicemente il sistema F, ma piuttosto una versione ristretta di $\lambda \omega$ chiamata sistema FC^3 .

Quest'ultima include anche i costruttori di tipo (funzioni di tipo in **Funx**), frenando però il polimorfismo ai cosiddetti tipi polimorfici di rango 1 (polimorfismo predicativo): tale limitazione si manifesta nella scrittura di tutti i quantificatori universali all'inizio di un tipo polimorfo (che prende il nome di schema di tipo).

Le versioni invece più espressive e più vicine a $\lambda\omega$ sono:

- polimorfismo di rango superiore: supporta quantificatori universali in qualsiasi punto nelle definizioni delle funzioni (e.g. Bool -> (forall b . b -> b)); Haskell lo realizza con l'estensione RankNTypes del compilatore GHC, mentre offre anche l'estensione Rank2Types, per la quale l'inferenza rimane decidibile;
- polimorfismo impredicativo: permette di quantificare le variabili di tipo in modo arbitrario, anche e soprattutto all'interno dei costruttori di tipo (e.g. Maybe (forall a . a -> a) -> Bool, possibile in Haskell abilitando l'estensione ImpredicativeTypes).

Il linguaggio **Funx** ovviamente non è correntemente in grado di supportare queste estensioni del sistema di tipo, così come non è possibile definire nuovi tipi o fare uso di *classi di tipo* simili a quelle proprie di Haskell. Affermare che **Funx** adotti il *sistema FC* potrebbe lasciare intendere un linguaggio più espressivo di quanto non sia in realtà: è dunque più opportuno realizzare il *sistema HM*, di cui il *sistema FC* è un ampliamento, e che comunque ben si presta allo scopo principe di traduzione in Java.

In Tabella 3.1 si possono osservare i tipi di alcune funzioni polimorfe di Haskell: la sintassi di **Funx** è molto simile (identica in ognuno dei casi presentati), con l'eccezione che la parola chiave forall è completamente assente dal linguaggio, in quanto ogni identificatore che inizia con una lettera minuscola è considerato una variabile di tipo da quantificare universalmente (sezione 5.1.1).

 $^{^2\}mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime}}}\mbox{\ensuremath{^{\prime\prime}}}\mbox{\$

³ «System FC, as implemented in GHC» [Eis15]

Funzione	Schema
id	forall a . a -> a
const	forall a b . a -> b -> a
(.)	forall b c a . (b -> c) -> (a -> b) -> a -> c
flip	forall a b c . (a -> b -> c) -> b -> a -> c
(\$)	forall a b . (a -> b) -> a -> b
(&)	forall a b . a -> (a -> b) -> b

Tabella 3.1: Esempi di funzioni polimorfe

In Figura 3.3 è mostrata la grammatica per la definizione dei tipi implementati nel linguaggio **Funx**. Si noti come i tipi monomorfi siano solo variabili di tipo o applicazioni di funzioni ad altri tipi; al momento il linguaggio mette a disposizione le funzioni di tipo più elementari, la cui arietà è indicata in pedice.

Schema di tipo
$$\sigma ::= \tau \mod \operatorname{politipo}$$

$$| \forall \alpha . \sigma \mod \operatorname{politipo}$$
 Tipo
$$\tau ::= \alpha \qquad \operatorname{variabile di tipo}$$

$$| F \tau . . . \tau \mod \operatorname{di tipo}$$
 Funzione di tipo
$$F ::= \to_2 \qquad \operatorname{funzione}$$

$$| Bool_0 \qquad \operatorname{booleano}$$

$$| Int_0 \qquad \operatorname{intero}$$

Figura 3.3: Grammatica del sistema di tipo di Funx

3.2 Inferenza secondo Hindley-Milner

Come già accennato, il sistema *Hindley–Milner* $(HM)^4$, o *Damas-Hindley-Milner*⁵, è un sistema di tipo per il lambda calcolo con polimorfismo parametrico largamente utilizzato in molti moderni linguaggi di programmazione ad alto livello. Il maggiore punto di forza del sistema è il relativo metodo di inferenza, in grado di dedurre automaticamente il tipo di un termine senza annotazioni esplicite fornite dagli sviluppatori.

Prima di presentare l'algoritmo di inferenza è necessario complementare le nozioni di lambda calcolo esteso (Figure 2.1 e 2.2) e del sistema di **Funx** (Figura 3.3) con due concetti fondamentali (Figura 3.4):

- contesto: una insieme di associazioni tra variabili e schemi di tipo, che rappresenta lo stato corrente dell'ambiente in cui un termine viene tipato; l'unione tra la grammatica del linguaggio e il sistema di tipi è data da un giudizio di tipo effettuato nel contesto su un termine (espressione);
- variabili libere: l'insieme delle variabili libere di un tipo è semplicemente il complemento delle variabili vincolate, quantificate universalmente in un politipo.

Contesto
$$\Gamma ::= \epsilon \qquad \text{contesto vuoto}$$

$$\mid \Gamma + x \colon \sigma \quad \text{aggiunta di associazione}$$
 Giudizio di tipo
$$::= \Gamma \vdash E \colon \sigma$$

$$free(\forall \ \alpha \ . \ \sigma) = free(\sigma) - \{\alpha\}$$
 tipo polimorfo
$$free(\alpha) = \{\alpha\}$$
 variabile di tipo
$$free(F \ \tau_1 \dots \tau_n) = \bigcup_{i=1}^n free(\tau_i)$$
 applicazione di funzione di tipo
$$free(\Gamma) = \bigcup_{x: \ \sigma \in \Gamma} free(\sigma)$$
 contesto
$$free(\Gamma \vdash E: \ \sigma) = free(\sigma) - free(\Gamma)$$
 giudizio di tipo

Figura 3.4: Definizioni di contesto e variabili libere

Le regole di inferenza⁶ del *sistema HM*, riportate in Figura 3.5, informano il comportamento dell'*algoritmo* W, implementazione dell'inferenza di tipo.

⁴ «The Principal Type-Scheme of an Object in Combinatory Logic» [Hin69] and «A Theory of Type Polymorphism in Programming» [Mil78]

⁵ «Principal type-schemes for functional programs» [DM82]

⁶«A Simple Applicative Language: Mini-ML» [Clé+86]

In aggiunta a principi già noti, le peculiarità non immediatamente chiare sono:

- constantType: funzione che restituisce il tipo di una costante;
- $\sigma \sqsubseteq \tau$: indica intuitivamente che σ è più generale di τ (τ è un'istanza di σ);
- $Clos_{\Gamma}$: ottiene la *chiusura*, ossia tipo più generale, di una variabile quantificando universalmente le variabili libere del tipo iniziale.

$$\frac{\tau = constantType(c)}{\Gamma \vdash c : \tau} \qquad [costante]$$

$$\frac{x : \sigma \in \Gamma \qquad \sigma \sqsubseteq \tau}{\Gamma \vdash x : \tau} \qquad [variabile]$$

$$\frac{\Gamma \vdash E_l : \tau \to \beta \qquad \Gamma \vdash E_r : \tau}{\Gamma \vdash E_l E_r : \beta} \qquad [applicazione]$$

$$\frac{\Gamma + x : \beta \vdash E : \tau}{\Gamma \vdash \lambda x . E : \beta \to \tau} \qquad [astrazione]$$

$$\frac{\overline{\Gamma} = \Gamma + \vec{x} : \vec{\beta}}{\overline{\Gamma} \vdash \vec{E} : \vec{\kappa} \qquad \overline{\Gamma} \{Clos_{\overline{\Gamma}}(\vec{\kappa})/\vec{\beta}\} \vdash E_i : \tau}}{\overline{\Gamma} \vdash \text{let } \vec{x} = \vec{E} \text{ in } E_i : \tau} \qquad [let]$$

$$\frac{\Gamma \vdash E_c : Bool \qquad \Gamma \vdash E_t : \tau \qquad \Gamma \vdash E_e : \tau}{\Gamma \vdash \text{if } E_c \text{ then } E_t \text{ else } E_e : \tau} \qquad [if]$$

Figura 3.5: Regole di inferenza del sistema HM in Funx

L'algoritmo W^7 riportato in Figura 3.6 fornisce un'implementazione del procedimento finora descritto, servendosi delle regole di inferenza e dettagliando i passi per la deduzione del tipo di ogni espressione disponibile in **Funx**.

L'algoritmo appare nel codice del compilatore in una forma molto simile, seppur talvolta più complessa, come nel caso dell'espressione let (sezione 5.3.2).

⁷ «Proofs about a Folklore Let-Polymorphic Type Inference Algorithm» [LY98]

$$\begin{array}{lll} \mathcal{W}(\Gamma,c) & = & (id,constantType(c)) \\ \mathcal{W}(\Gamma,x) & = & \operatorname{let} & \forall \vec{\alpha} \cdot \tau = \Gamma(x), \ new \ \vec{\beta} \\ & & \operatorname{in} & (id,\{\vec{\beta}/\vec{\alpha}\}\tau) \\ \mathcal{W}(\Gamma,E_l \ E_r) & = & \operatorname{let} & (S_l,\tau_l) = \mathcal{W}(\Gamma,E_l) \\ & & (S_r,\tau_r) = \mathcal{W}(S_l\Gamma,E_r) \\ & & S_a = \mathcal{U}(S_r\tau_l,\tau_r \to \beta), \ new \ \beta \\ & & \operatorname{in} & (S_aS_rS_l,S_a\beta) \\ \mathcal{W}(\Gamma,\lambda x \cdot E) & = & \operatorname{let} & (S,\tau) = \mathcal{W}(\Gamma+x:\beta,E), \ new \ \beta \\ & & \operatorname{in} & (S,S\beta \to \tau) \\ \mathcal{W}(\Gamma,\operatorname{let} \ \vec{x} = \vec{E} \ \operatorname{in} \ E_l) & = & \operatorname{let} & \overline{\Gamma} = \Gamma + \vec{x} : \vec{\beta}, \ new \ \vec{\beta} \\ & & (\vec{S},\vec{\kappa}) = \mathcal{W}(\overline{\Gamma},\vec{E}) \\ & & (S_l,\tau) = \mathcal{W}(\vec{S} \ \overline{\Gamma}\{Clos_{\vec{S} \ \overline{\Gamma}}(\vec{\kappa})/\vec{\beta}\},E_l) \\ & & \operatorname{in} & (S_l\vec{S},\tau) \\ \mathcal{W}(\Gamma,\operatorname{if} E_c \ \operatorname{then} \ E_t \ \operatorname{else} \ E_e) & = & \operatorname{let} & (S_c,\tau_c) = \mathcal{W}(\Gamma,E_c) \\ & & (S_l,\tau_l) = \mathcal{W}(S_c\Gamma,E_l) \\ & & (S_e,\tau_e) = \mathcal{W}(S_lS_c\Gamma,E_e) \\ & & S_{cb} = \mathcal{U}(\tau_c,Bool) \\ & S_{te} = \mathcal{U}(S_e\tau_l,\tau_e) \\ & \operatorname{in} & (S_l\varepsilon_S_c)S_eS_lS_c,S_l\varepsilon_l\tau_l) \end{array}$$

 $\mathcal{W}: Context \times Expression \rightarrow Substitution \times Type$

Figura 3.6: Algoritmo W

Dato un contesto in cui analizzare un'espressione, W restituisce un tipo per l'espressione e una sostituzione. Quest'ultima può essere vuota (id), generata manualmente $(\{\tau_2/\tau_1\})$ o dall'unificazione di altri tipi, e rappresenta una mappatura tra variabili di tipo e altri tipi; può essere applicata a tipi e contesti.

La funzione *new* esprime la creazione di nuove variabili di tipo, con il vincolo che non siano state ancora usate dall'algoritmo.

Infine, l'unificazione (funzione \mathcal{U}) è un'operazione altrettanto importante per l'inferenza di tipo, con la quale si cerca di trovare una sostituzione che renda due tipi uguali.

$$\mathcal{U}: Type \times Type \rightarrow Substitution$$

$$\begin{array}{ccc} \mathcal{U}(\alpha, \alpha) & = & id \\ \mathcal{U}(\alpha, \tau) & = & \{\tau/\alpha\} \\ \mathcal{U}(\tau, \alpha) & = & \{\tau/\alpha\} \\ \mathcal{U}(F \; \vec{\tau}, F \; \vec{\kappa}) & = & \mathcal{U}(\vec{\tau}, \vec{\kappa}) \end{array}$$

Figura 3.7: Funzione \mathcal{U}

4. Java

Parallelamente alle prime fasi di sviluppo è stata svolta un'analisi di Java¹ per valutare quali fossero le caratteristiche del linguaggio utili alla traduzione di codice **Funx**.

Questo capitolo riporta pertanto una breve panoramica delle principali funzionalità impiegate, accompagnate da esempi di traduzione che illustrano alcuni dei risultati ottenibili con il compilatore (si ricorda che altri esempi sono esibiti durante il Capitolo 5).

Le funzioni non dichiarate all'interno degli esempi stessi provengono dalla piccola libreria standard (suddivisa in FunxPrelude e JavaPrelude), parzialmente presentata nella Tabella 2.1 con gli operatori simbolici.

4.1 Interfacce funzionali

Nel tradurre un linguaggio funzionale viene naturale pensare immediatamente alle *inter-facce funzionali* e *lambda espressioni* introdotte in Java 8² per rappresentare funzioni anonime: l'interfaccia generica Function è la più adatta a riprodurre il comportamento dell'astrazione, come mostrato nei Codici 4.1 e 4.2.

```
constant : a -> b -> a
constant x = \y -> x
```

Codice 4.1: Semplice funzione in **Funx**

```
public static <a, b> Function<a, Function<b, a>> constant() {
   return (x -> (y -> x));
}
```

Codice 4.2: Corrispondente metodo in Java

Dato il naturale *currying* di oggetti Function, questo tipo di traduzione ha il vantaggio di permettere l'applicazione parziale di funzioni (tramite una sequenza di apply() in numero minore rispetto al totale degli input), ma il grande svantaggio della creazione di una nuova istanza della funzione per ogni chiamata.

Poiché constant ha tipo polimorfo (sezione 4.3), il metodo utilizza parametri di tipo e deve quindi necessariamente restituire un nuovo oggetto con ogni chiamata: nonostante la performance delle traduzioni non sia un obiettivo primario del progetto, la versione attuale del compilatore fa uso di alcune piccole ottimizzazioni nella trasposizione delle funzioni monomorfe, approfondite nella sezione 5.4.3.

OpenJDK (https://openjdk.org)

²OpenJDK 8 (https://openjdk.org/projects/jdk8)

In aggiunta alla classe Function, nella parte nativa (codice Java) della libreria standard di **Funx** è definita un'ulteriore interfaccia funzionale per creare espressioni let: in questo caso vi è un grande utilizzo di classi anonime, potenzialmente annidate, rappresentanti le dichiarazioni locali e l'espressione principale (metodo eval).

```
1    @FunctionalInterface
2    public interface Let<T> {
3         T _eval();
4    }
```

Codice 4.3: Interfaccia funzionale per espressioni let

```
hundredsSum : Int -> Int -> Int
hundredsSum = let

on : (a -> a -> b) -> (c -> a) -> c -> b
on op f x y = op (f x) (f y)
in on add (multiply 100)
```

Codice 4.4: Espressione let in Funx

```
public static Function<Long, Function<Long, Long>> hundredsSum;
2
3
   static (
4
      hundredsSum = (new Let<>() {
         private <a, b, c>
5
            Function<
6
                   Function<a, Function<a, b>>,
7
                   Function<Function<c, a>, Function<c, Function<c, b>>>>
8
9
                on() {
             return (op -> (f -> (x -> (y -> op.apply(f.apply(x)).apply(f.apply(y))))));
10
11
         }
12
13
         @Override
14
         public Function<Long, Function<Long, Long>> _eval() {
            return this.<Long, Long>on().apply(add).apply(multiply.apply(100L));
15
16
17
       })._eval();
18
```

Codice 4.5: Corrispondente classe anonima in Java

Nei Codici 4.4 e 4.5 si può vedere che la funzione hundredsSum è implementata attraverso la chiamata al metodo principale dell'interfaccia funzionale Let, realizzato internamente alla classe anonima con il supporto del metodo polimorfo on.

Inoltre, è immediatamente evidente come le traduzioni in Java siano progressivamente più complesse e meno leggibili con l'introduzione di nuove funzionalità: l'esempio più eclatante è dato proprio dal tipo di ritorno del metodo locale on, divenuto di difficile comprensione rispetto alla sintassi molto concisa del linguaggio funzionale.

4.2 Operatore ternario

Una delle peculiarità della traduzione da **Funx** a Java è l'uso dell'operatore ternario (condition ? thenBranch : elseBranch) ogni qualvolta siano presenti espressioni condizionali if-then-else.

I linguaggi funzionali sfruttano spesso una caratteristica (non menzionata nella sezione 2.1) che prende il nome di *lazy evaluation* (valutazione pigra): fino a quando il risultato di un'espressione non è richiesto per un successivo calcolo, questa non verrà completamente valutata.

Oltre ad offrire molteplici possibilità di ottimizzazione dal punto di vista del tempo di esecuzione, tale comportamento è molto comodo nella scrittura di funzioni che per esempio potrebbero terminare prima del previso o magari effettuare computazioni su strutture dati infinite. I linguaggi che sono lazy evaluated di default impegano nella maggior parte dei casi un garbage collector per liberare la memoria occupata dalle espressioni non valutate e non più rilevanti.

Il linguaggio Java non adotta la lazy evaluation di default se non in casi particolari, tra cui gli operatori booleani binari, il costrutto if-then-else (e corrispondente operatore ternario) e altre funzionalità più avanzate tra cui gli stream e le lambda espressioni già viste. Utilizzando quest'ultime si potrebbero ottenere risultati simili, in termini di valutazione pigra, a quelli di un linguaggio funzionale; tuttavia, rendere Funx un linguaggio completamente pigro avrebbe comportato una traduzione indubbiamente ancora più complessa, molteplici rischi di peggiorare le prestazioni dei programmi e un'implementazione del compilatore che va oltre lo scopo di questo progetto.

Nonostante ciò, la scelta di ridurre gli operatori booleani binari (and e or) ad espressioni con operatore ternario è stata considerata quasi obbligatoria per conservarne la natura pigra: gli operatori ternari utilizzati a questo scopo derivano direttamente dalla costruzione dell'AST (sezione 5.2.2), motivo per cui non vengono riconvertiti in operatori nativi di Java in fase di traduzione.

```
power : Int -> Int -> Int
power b e = if e == 0 then 1 else b * power b (e - 1) fi

xor : Bool -> Bool -> Bool
xor a b = (a || b) && !! (a && b)
```

Codice 4.6: If e operatori booleani in **Funx**

```
public static Function<Long, Function<Long, Long>> power;
1
2
    public static Function<Boolean, Function<Boolean, Boolean>> xor;
3
4
5
       power = (b -> (e -> ((JavaPrelude.<Long>equalsEquals().apply(e).apply(OL))
6
          ? (1L)
8
          : (multiply.apply(b)
9
             .apply(power.apply(b).apply(subtract.apply(e).apply(1L)))));
10
       xor = (a \rightarrow (b \rightarrow
11
12
          ((((a) ? (true) : (b))) ? (not.apply(((a) ? (b) : (false)))) : (false))));
13
```

Codice 4.7: Corrispondenti operatori ternari in Java

4.3 Tipi generici

Il sistema di tipo di **Funx** necessita la traduzione di funzioni polimorfe, e la soluzione più semplice e idiomatica in Java è l'utilizzo dei *generics*: tramite i parametri di tipo generici è possibile definire classi e metodi che agiscono su molteplici tipi di dati, implementando comportamenti che possono essere condivisi dai diversi elementi del dominio di tipi delle funzioni rappresentate.

Nel contesto del *sistema HM* di **Funx**, le variabili quantificate universalmente nei politipi hanno una diretta corrispondenza con i parametri di tipo che possono essere dichiarati tra i modificatori di visibilità e il tipo di ritorno di un metodo, il quale a sua volta combacia con la parte interna dello schema di tipo.

Nei Codici 4.8 e 4.9 si può notare come Java non sia in grado di inferire i tipi desiderati per le funzioni polimorfe: queste devono infatti essere istanziate esplicitamente usando la classe di appartenenza e le parentesi angolari (questa limitazione richiederà alcuni espedienti in casi limite illustrati nelle sezioni 5.4.4 e 5.4.5).

Codice 4.8: Scrittura e utilizzo di funzioni polimorfe in Funx

```
public static Function<Long, Long> sumToN;
1
2
   static {
3
4
      sumToN = (new Let<>() {
         private <a, b, c>
5
            Function<
6
                Function<a, Function<b, c>>,
8
                Function<Function<a, b>, Function<a, c>>>
9
                  ap() {
10
             return (op -> (f -> (x -> op.apply(x).apply(f.apply(x)))));
          }
11
12
          @Override
         public Function<Long, Long> _eval() {
14
15
            return FunxPrelude.<Long, Long, Long>compose()
                .apply(FunxPrelude. <Long, Long>flip().apply(divide).apply(2L))
16
                .apply(this.<Long, Long, Long>ap().apply(multiply).apply(add.apply(1L)));
17
18
      })._eval();
19
20
```

Codice 4.9: Corrispondenti proprietà e metodi Java

5. Compilatore

Il software per il progetto è stato sviluppato mantenendo il codice sul repository GitHub $\mathbf{Funx-jt}^1$, nel cui nome "jt" è l'acronimo per " $Java\ Transpiler$ ".

La prima release stabile è disponibile sul repository (Funx-jt-0.1.1) con una *Command Line Interface* per traduzione ed esecuzione di programmi **Funx**; è stato utilizzato Gradle² per la compilazione e la gestione delle dipendenze, assieme alla più recente versione *Long Term Support (LTS)* di Java, OpenJDK 21³.

Nel corso di questo capitolo si discuteranno le fasi di compilazione e la struttura del software, analizzando nel dettaglio le parti più importanti.

```
Usage: Funx-jt [-hV] [COMMAND]

A Funx to Java source transpiler.

-h, --help Show this help message and exit.

-V, --version Print version information and exit.

Commands:

t Transpile a funx program

r Run a funx program
```

```
Usage: Funx-jt t [-adFhIJp] [-o=<outputDir>] <input>
Transpile a funx program
                             Input funx source file
     <input>
                             Output abstract syntax tree visualization
  -a, --ast
  -d, --dot
                             Keep .dot file after AST visualization
  -F, --no-fancy-types
                             Don't use fancy types for inference annotations
     --help
                             Show this help message and exit.
      --no-inference
                             Omit AST type inference annotations
                             Skip Java transpilation
      --no-java
                             Output directory
  -o, --output=<outputDir>
  -p, --parse-tree
                             Output raw parse tree visualization
```

Figura 5.1: Possibili comandi e opzioni della *CLI*

 $^{^{1}}massimopavoni/Funx-jt\;(\texttt{https://github.com/massimopavoni/Funx-jt})$

²Gradle Build Tool (https://gradle.org)

³OpenJDK 21 (https://openjdk.org/projects/jdk/21)

5.1 ANTLR

Al fine di semplificare lo sviluppo di *lexer* e *parser* per il linguaggio funzionale ideato è stato scelto il generatore di *parser* chiamato ANTLR⁴.

Grazie a tale strumento il processo iterativo di creazione della grammatica di **Funx** è stato notevolmente semplificato e accelerato, in quanto ANTLR mette a disposizione del programmatore un linguaggio per definire uno o più file di specifica per lessico e sintassi (directory Funx-jt/src/main/antlr nel repository): questi vengono poi processati per generare il codice sorgente del *lexer* e del *parser*.

5.1.1 Analisi lessicale

Data la probabile complessità delle regole della grammatica di **Funx**, fin dall'inizio la definizione dei *token* (lessemi) del linguaggio è stata separata dalla specifica del *parser*. Il file FunxLexer.q4 descrive i lessemi dividendoli nelle seguenti cateogorie:

- 1. whitespace: caratteri di spaziatura e tabulazione;
- 2. comments: commenti di linea e blocco;
- 3. keywords: parole chiave del linguaggio;
- 4. Java keywords: parole chiave del linguaggio Java, da evitare;
- 5. types: tipi di dato (funzioni di tipo con arità 0);
- 6. literals: costanti booleane e numeriche;
- 7. variables: identificatori per variabili di tipo o nomi di funzioni;
- 8. module: identificatori il modulo;
- 9. vari operatori simbolici per:
 - bool: valori booleani;
 - comparison: confronti tra numeri;
 - arithmetic: operazioni aritmetiche;
 - other symbols: simboli della sintassi (come ->) e varie funzioni di libreria;
 - delimiters: parentesi tonde, quadre e graffe.

Le categorie 1 e 2 contengono token da scartare, tranne NEWLINE, mentre la categoria 4 è utile qualora eventualmente si permetta allo sviluppatore di utilizzare tali parole chiave riservate, effettuando una rinomina automatica; le categorie 7 e 8 devono necessariamente apparire dopo le categorie 3 e 4, poiché tra *keyword* e identificatori di ogni genere le prime devono avere la precedenza (la posizione della categoria 5 tiene conto di una possibile futura estensione per consentire la creazione di nuovi tipi).

Oltre alle categorie illustrate, in testa al file sono presenti dei cosiddetti fragment (frammenti) che semplificano le espressioni regolari dei token e complessivamente aumentano la leggibilità della specifica.

⁴ANother Tool for Language Recognition; «ANTLR: A predicated-LL(k) parser generator» [PQ95], The Definitive ANTLR 4 Reference [Par13] and ANTLRv4 (https://www.antlr.org)

```
lexer grammar FunxLexer;
2
    // Fragments
3
   fragment LALPHA: [a-z];
   fragment UALPHA: [A-Z];
5
    fragment ALPHA: LALPHA | UALPHA;
6
   fragment ALPHA_: ALPHA | UnderScore;
8
    fragment DIGIT: [0-9];
   fragment DECIMAL: DIGIT+;
10
11
12
    // Whitespace
13 NEWLINE: '\r'? '\n' | '\r';
14
15
    TAB: [\t]+ \rightarrow skip;
   WS: [\u0020\u00a0\u1680\u2000\u200a\u202f\u205f\u3000]+ -> skip;
16
17
    // Comments
18
   CloseMultiComment: './';
19
   OpenMultiComment: '/.';
   SingleComment: '//';
21
22
23 | COMMENT: SingleComment ~[\r\n]* -> skip;
   MULTICOMMENT: OpenMultiComment .*? CloseMultiComment -> skip;
24
25
    // Keywords
26
   ELSE: 'else';
27
   FI: 'fi';
28
  IF: 'if';
29
  IN: 'in';
30
31
    LET: 'let';
32
    // Java keywords
34
   RESERVED_JAVA_KEYWORD: 'abstract' | 'assert' | 'boolean' | 'break' | 'byte' | [...];
35
36
   // Types
   TYPE: BOOLTYPE | INTTYPE;
37
   BOOLTYPE: 'Bool';
38
    // Literals
40
   INT: DECIMAL | OpenParen '-' DECIMAL CloseParen;
41
42
    // Variables
43
44
    VARID: LALPHA (ALPHA_ | DIGIT) *;
45
    // Module
46
47
   MODULEID: UALPHA (ALPHA_ | DIGIT) *;
48
   // Bool
49
    And: '&&';
50
   Not: '!!';
51
    // Comparison
53
  EqualsEquals: '==';
54
   NotEquals: '!=';
56
    // Arithmetic
57
   Add: '+';
58
59
    // Other symbols
60
   UnderScore: '_';
61
   Arrow: '->';
62
64 // Delimiters
65 OpenParen: '(';
    CloseParen: ')';
66
```

Codice 5.1: Alcuni token del lexer

5.1.2 Analisi sintattica

Il file FunxParser.g4 contiene le regole concrete della grammatica di Funx: nonostante la somiglianza con le grammatiche delle Figure 2.2 e 3.3, è evidente che queste non collimino esattamente a causa di zucchero sintattico e requisiti di ANTLR.

Lo strumento utilizzato, infatti, è un generatore di parser di tipo top-down per grammatiche LL, le quali in generale non supportano regole ricorsive a sinistra.

Essendo tali regole spesso comuni nella definizione di qualsiasi linguaggio di programmazione, **Funx** incluso, ANTLRv4 offre un diverso tipo di parsing, detto $Adaptive\ LL(*)^5$: quest'ultimo è in grado di riscrivere automaticamente le grammatiche, eliminando la ricorsione a sinistra diretta (e.g. linee 36 e 38-43), così da non incorrere in regole ambigue che potrebbero causare backtracking e conseguente overhead.

Il Codice 5.2 riporta integralmente le regole concrete della sintassi di Funx, tra cui:

- module: nome del modulo, funzione main opzionale e dichiarazioni globali;
- main: funzione main, diversa dalle dichiarazioni classiche per l'assenza di schema di tipo e parametri lambda;
- declaration: funzione con nome, tipo e parametri (e opzionalmente with per funzioni locali);
- typeElems: tipo di una funzione, definito ricorsivamente secondo la grammatica del sistema di tipo di Funx;
- statement: per evitare ricorsione a sinistra indiretta, la separazione tra statement e expression forza l'uso di parentesi nei casi in cui lambda astrazioni, let e if siano usati all'interno di un'espressione;
- expression: racchiude l'applicazione funzionale, tutte le regole relative agli operatori simbolici, specificandone la priorità implicite (Tabella 2.1), e le espressioni primarie (costanti, variabili e parentesi per controllare la precedenza);
- *lambda*, *let*, *if*: corrispondenti alle produzioni per astrazione, let e if della grammatica formale.

 $^{^5}$ «LL(*): the foundation of the ANTLR parser generator» [PF11] and «Adaptive LL(*) parsing: the power of dynamic analysis» [PHF14]

```
parser grammar FunxParser;
2
   options { tokenVocab = FunxLexer; }
3
4
   module: (MODULE MODULEID (Dot MODULEID) * NEWLINE+)?
5
6
       (main NEWLINE+)? declarations EOF;
   declarations: declaration (NEWLINE declaration?) *;
8
9
   main: id = MAIN Equals statement with?;
10
11
12
    // Declaration
   declaration: (declarationScheme NEWLINE)?
13
      id = VARID lambdaParams? Equals statement with?;
14
15
   declarationScheme: id = VARID Colon typeElems;
16
17
   with: NEWLINE WITH localDeclarations OUT;
18
19
   localDeclarations: NEWLINE declarations NEWLINE;
20
21
    // Type
22
   typeElems: OpenParen typeElems CloseParen # parenType
23
      | VARID # typeVar
24
25
      | TYPE # namedType
      | <assoc = right> typeElems Arrow typeElems # arrowType;
26
27
28
   statement: expression # expressionStatement
29
30
      | lambda # lambdaStatement
      | let # letStatement
31
      | ifS # ifStatement;
32
33
   // Expression
34
   expression: primary # primExpression
35
      | expression expression # appExpression
      | <assoc = right> expression bop = Dot expression # composeExpression
37
      | expression bop = (Divide | Modulo | Multiply) expression # divModMultExpression
38
39
      | expression bop = (Add | Subtract) expression # addSubExpression
      expression
40
41
         bop = (GreaterThan | GreaterThanEquals | LessThan | LessThanEquals)
         expression # compExpression
42
      | expression bop = (EqualsEquals | NotEquals) expression # eqExpression
43
44
      | uop = Not expression # notExpression
      | <assoc = right> expression bop = And expression # andExpression
45
      | <assoc = right> expression bop = Or expression # orExpression
46
47
      | <assoc = right> expression bop = Dollar expression # rightAppExpression;
48
49
   primary: OpenParen statement CloseParen # parenPrimary
      constant # constPrimary | VARID # varPrimary;
50
51
    // Lambda
52
   lambda: Backslash lambdaParams? Arrow statement;
53
54
   lambdaParams: VARID+;
56
57
   let: LET localDeclarations IN statement;
58
59
60
   ifS: IF statement THEN statement ELSE statement FI;
61
62
63
   constant: BOOL | numConstant;
64
66
   numConstant: INT;
```

Codice 5.2: Grammatica per il parser

5.2 Albero sintattico astratto

Il parser generato da ANTLR utilizza i token identificati dal lexer per costruire un albero di parsing concreto (CST, concrete syntax tree), molto complesso e poco comprensibile. È dunque opportuno astrarre i dettagli del parsing in una struttura più semplice e facile da interpretare, che rispecchia precisamente la grammatica del linguaggio (Figura 2.2). Tale operazione è effettuata dalla grande maggioranza dei compilatori moderni e il risultato è chiamato AST, abstract syntax tree (albero sintattico astratto).

5.2.1 Gerarchia delle classi

Il primo passo per la costruzione di un **AST** per la sintassi di **Funx** è la definizione di una gerarchia di classi Java che rappresentano i nodi dell'albero (package com.github.massimopavoni.funx.jt.ast.node).

La classe astratta ASTNode è la radice dell'ordinamento poiché sarà usata per gli oggetti creati a partire dal CST: contiene la proprietà inputPosition per facilitare la segnalazione di errori e vincola le classi figlie all'implementazione del metodo astratto accept per visitare i nodi.

Un'altra classe astratta, derivata dalla precedente, è Expression, la quale identifica un'espressione ed è dotata di alcuni campi e metodi utili all'inferenza di tipo.

Ogni altra sottoclasse (ad eccezione di Declarations, utilizzata per dichiarazioni globali e locali) è una trascrizione in Java delle produzioni della grammatica formale:

- Module: modulo del programma;
- Declaration: dichiarazione di funzione;
- Constant: termini costanti;
- Variable: simboli per variabili;
- Application: applicazione di funzione;
- Lambda: astrazione per le funzioni anonime;
- Let: contenitore di dichiarazioni locali;
- If: costrutto condizionale.

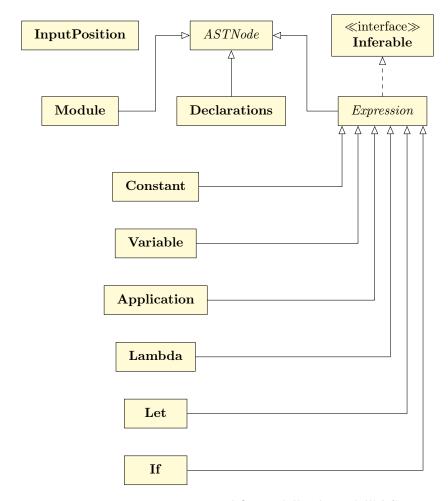


Figura 5.2: Diagramma semplificato delle classi dell'AST

```
public static final class Lambda extends Expression {
      public final String paramId;
2
3
      public final Expression expression;
4
      public Lambda(InputPosition inputPosition, String paramId, ASTNode expression) {
5
         super(inputPosition); // ASTNode constructor
         this.paramId = paramId;
7
         this.expression = (Expression) expression;
8
10
      @Override // from Inferable interface
11
      public Utils.Tuple<Substitution, Type> infer(Context ctx) { ... }
12
13
14
      @Override // from Expression abstract class
      protected void propagateSubstitution(Substitution substitution) { ... }
15
16
      @Override // from ASTNode abstract class
17
      public <T> T accept (ASTVisitor<? extends T> visitor) {
18
         return visitor.visitLambda(this);
19
20
21
```

Codice 5.3: Esempio di classe della gerarchia dell'AST

5.2.2 AST builder

ANTLR offre due diversi approcci per analizzare l'albero di parsing:

- *listener*: i metodi implementati per l'analisi dei nodi sono chiamati seguendo la ricerca in profondità (*DFS*, *depth-first search*);
- *visitor*: i nodi possono essere visitati arbitrariamente tramite il metodo visit, senza seguire un ordine specifico; non tutti i metodi devono essere implementati ed è possibile ignorare dei nodi o ri-visitarli.

La seconda opzione è indubbiamente più versatile, e può essere per esempio anche utilizzata qualora si desideri evitare completamente la costruzione di un **AST** e chiamare i metodi di visita per eseguire il codice (e.g. linguaggi interpretati).

Nel caso di **Funx-jt** la scelta ricade appunto sul *visitor* in virtù della probabilità di dover "saltare" alcuni nodi e ottenerne direttamente le informazioni interne.

Durante la compilazione del progetto Java, Gradle è configurato per generare le seguenti classi nel package com.github.massimopavoni.funx.jt.parser:

- FunxLexer: *lexer*;
- FunxParser: parser;
- FunxParserVisitor: interfaccia generica per differenti implementazioni del *visitor* (estende l'interfaccia ParseTreeVisitor di ANTLR);
- FunxParserBaseVisitor: classe predefinita che percorre l'intero albero di parsing (estende la classe astratta AbstractParseTreeVisitor per ereditare alcuni metodi standard come visitChildren).

La classe ASTBuilder estende a sua volta FunxParserBaseVisitor e sovrascrive quasi tutti i metodi ereditati; in particolare, ASTBuilder effettua la composizione degli schemi di tipo definiti dall'utente (sezione 5.3.1) e l'eliminazione dello zucchero sintattico mediante l'uso di alcune proprietà e metodi ausiliari.

Inoltre, all'interno del package com.github.massimopavoni.funx.jt.ast viene definita una classe enumeratore, PreludeFunction contenente le funzioni di libreria standard, con i relativi simboli e gli schemi di tipo corrispondenti.

```
public enum PreludeFunction {
1
      COMPOSE(".", "compose",
2
         new Scheme(Set.of(OL, 1L, 2L),
3
             arrowOf(arrowOf(ZERO, ONE), arrowOf(TWO, ZERO), TWO, ONE)), false);
4
5
      public final String symbol;
6
      public final String id;
7
      public final Scheme scheme;
8
9
      public final boolean nativeJava;
10
      PreludeFunction(String symbol, String id,
11
12
         Scheme scheme, boolean nativeJava) { ... }
13
      public static PreludeFunction fromSymbol(String symbol) {
14
         return Utils.enumFromField(PreludeFunction.class,
16
             f -> f.symbol.equals(symbol));
17
   }
```

Codice 5.4: Parte del codice di PreludeFunction

```
private ASTNode createLambdaChain(
2
          InputPosition position, Deque<String> params, ASTNode expression) {
3
       if (params.size() == 1)
          return new Expression.Lambda(
4
             position,
5
6
             params.getFirst(),
7
             expression);
8
      return new Expression.Lambda(
9
          position,
10
          params.pop(),
          createLambdaChain(position, params, expression));
11
12
13
14
   private ASTNode binarySymbolApplication(
15
          InputPosition position, String symbol, ASTNode left, ASTNode right) {
       return new Expression.Application(
16
17
          position,
          new Expression.Application(
18
19
                position,
                new Expression. Variable (
20
                      position,
21
22
                      PreludeFunction.fromSymbol(symbol).id),
23
                left),
          right);
24
25
```

Codice 5.5: Metodi per astrazioni annidate e operatori simbolici binari

```
public class ASTBuilder extends FunxParserBaseVisitor<ASTNode> {
1
2
       @Override
3
      public ASTNode visitAppExpression(FunxParser.AppExpressionContext ctx) {
         return new Expression.Application(getInputPosition(ctx),
4
             visit(ctx.expression(0)),
             visit(ctx.expression(1)));
6
7
9
       @Override
10
      public ASTNode visitComposeExpression(FunxParser.ComposeExpressionContext ctx) {
         return binarySymbolApplication(getInputPosition(ctx),
11
12
             Utils.fromLexerToken(ctx.bop.getType()),
13
             visit(ctx.expression(0)),
             visit(ctx.expression(1)));
14
15
       }
16
       @Override
17
      public ASTNode visitOrExpression(FunxParser.OrExpressionContext ctx) {
18
19
         // transform logical disjunction into if statement for lazy behavior
         return new Expression.If(getInputPosition(ctx),
20
             visit(ctx.expression(0)),
21
             new Expression.Constant(InputPosition.UNKNOWN, true),
22
23
             visit(ctx.expression(1)));
24
25
26
       @Override
27
      public ASTNode visitLambda(FunxParser.LambdaContext ctx) {
28
         // lambda params are syntactic sugar for a lambda chain
29
          return createLambdaChain(getInputPosition(ctx),
             ctx.lambdaParams().VARID().stream().map(ParseTree::getText)
30
31
                   .collect(Collectors.toCollection(ArrayDeque::new)),
32
                visit(ctx.statement()));
33
34
```

Codice 5.6: Alcuni metodi visit di ASTBuilder

Il codice del compilatore include una classe astratta ASTVisitor atta a permettere l'analisi dell'**AST** in modo simile ai *visitor* di ANTLR. Il Codice 5.7 e la Figura 5.3 mostrano un **AST** come verrebbe creato da ASTBuilder; la *CLI* sviluppata fornisce delle opzioni per la visualizzazione dell'albero, generata utilizzando il software Graphviz⁶ con un *visitor* (GraphvizBuilder) che scrive una stringa nel linguaggio DOT.

```
tautology : Bool -> Bool
tautology x = x || !!x
```

Codice 5.7: Programma in Funx

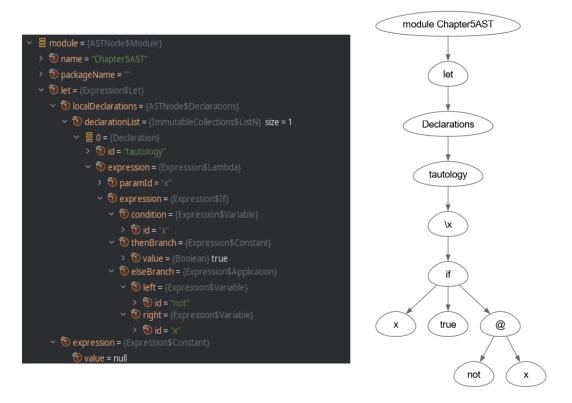


Figura 5.3: Oggetto **AST** in *debuq* e visualizzazione dell'albero

 $^{^6} Graph\ Visualization\ Software\ (\verb|https://graphviz.org|)$

5.3 Motore inferenziale

I sistemi di tipo e l'inferenza descritti nel Capitolo 3 costituiscono una parte imprescindibile del software, data l'incapacità di simulare il polimorfismo parametrico del sistema HM lasciando al compilatore Java il compito di inferire e controllare i tipi dei metodi (o classi) generici. In tal caso, infatti, la compilazione fallirebbe a causa di tipi "troppo generici" e type casting non permesso in maniera implicita (e.g. non si è in grado di conciliare ad esempio un tipo generico con una lambda espressione).

Figura 5.4: Esempio di errore in Java dovuto a tipi generici

La linea di codice citata in Figura 5.4 non è intrinsecamente errata, ma non può essere compilata in mancanza di informazioni riguardanti il parametro di tipo generico della funzione id (con tipo di ritorno Function<T, T>): il problema da risolvere è quindi conoscere il tipo dell'espressione in input alla prima chiamata al metodo apply.

Il motore inferenziale è la parte del compilatore che si occupa di stabilire i tipi delle espressioni seguendo le regole di inferenza e i passi dell'algoritmo W^7 descritti nella sezione 3.2; la fase di inferenza avviene subito dopo il parsing e la costruzione dell'**AST** e precede la generazione del codice Java.

5.3.1 Sistema HM

Seguendo la grammatica del sistema di tipo di **Funx** e similmente alla gerarchia per l'albero sintattico astratto, l'implementazione del *sistema HM* presenta le seguenti classi e sottoclassi:

- Scheme: schemi di tipo;
- Type: classe astratta per i monotipi;
- Error: tipo errore per la continuazione dell'inferenza;
- Boring: tipo vuoto per costanti con valore null;
- Variable: variabili di tipo;
- FunctionApplication: applicazione di funzione di tipo.

⁷ «Algorithm W Step by Step» [Gra06]

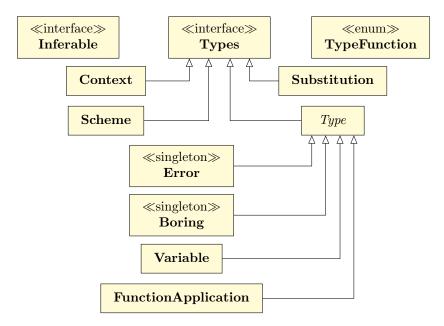


Figura 5.5: Diagramma semplificato delle classi del sistema HM

```
public static final class Variable extends Type {
1
2
       public final long id;
3
       public Variable(long id) { this.id = id; }
4
       public static String toString(long id) {
6
          return id < 26 ? Character.toString((char) ('a' + id)) : "t" + id;</pre>
7
8
9
       public static String toFancyString(long id) {
10
11
          return id < 24 ? Character.toString((char) (945 + id)) : "t" + id;</pre>
12
13
14
      public Set<Long> freeVariables() { ... }
15
16
17
       @Override
       public Type applySubstitution(Substitution substitution) { ... }
18
```

Codice 5.8: Esempio di sottoclasse di Type

Altre classi e interfacce di supporto sono fondamentali per la definizione dei comportamenti precedentemente descritti:

- Types: interfaccia per operazioni comuni negli oggetti che agiscono a stretto contatto con i tipi; specifica i metodi per il calcolo delle variabili libere e l'applicazione di una sostituzione;
- Inferable: interfaccia già visibile in Figura 5.2 e che identifica i nodi dell'**AST** che implementano un metodo di inferenza (i.e. le sottoclassi di Expression);
- TypeFunction: enumerazione delle funzioni di tipo disponibili;
- Substitution: lista di sostituzioni da variabili di tipo a monotipi;
- Context: contesto di inferenza con vincoli tra variabili e schemi di tipo.

```
package com.github.massimopavoni.funx.jt.ast.node;
2
3
   public sealed interface Inferable permits Expression {
      Utils.Tuple<Substitution, Type> infer(Context ctx);
5
6
   // -----
7
8
9
   package com.github.massimopavoni.funx.jt.ast.typesystem;
10
11
   sealed interface Types<T extends Types<T>>
12
         permits Type, Scheme, Substitution, Context {
      Set<Long> freeVariables();
13
14
15
      T applySubstitution(Substitution substitution);
16
```

Codice 5.9: Interfacce utili nel sistema HM

```
public final class Context implements Types<Context> {
      private final Map<String, Scheme> environment;
2
3
      public Scheme bindingOf(String variable) {
4
5
         return environment.get(variable);
6
7
8
      @Override
9
      public Set<Long> freeVariables() {
         return environment.values().stream().flatMap(s -> s.freeVariables().stream())
10
11
             .collect(ImmutableSet.toImmutableSet());
12
      }
13
      @Override
14
      public Context applySubstitution(Substitution substitution) {
15
16
         Context newCtx = new Context(this);
         newCtx.environment.replaceAll((v, s) -> s.applySubstitution(substitution));
17
18
         return newCtx;
19
      }
20
^{21}
22
   public final class Substitution implements Types<Substitution> {
      public static final Substitution EMPTY = new Substitution();
23
24
      private final Map<Long, Type> variableTypes;
25
      public Type substituteOf(Long variable) {
26
27
         return variableTypes.get(variable);
28
      }
29
       @Override
      public Set<Long> freeVariables() {
31
         // similar to Context
32
33
34
35
       @Override
      public Substitution applySubstitution(Substitution substitution) {
36
37
         return new Substitution(variableTypes.entrySet().stream()
38
             .collect(Collectors.toMap(Map.Entry::getKey,
                e -> e.getValue().applySubstitution(substitution))));
39
40
      }
41
```

Codice 5.10: Altre classi del sistema HM

5.3.2 Inferenza su espressioni

La classe InferenceEngine contiene solamente proprietà e metodi statici, e non adotta lo stesso procedimento di esplorazione dell'albero sintattico delle classi figlie di ASTVisitor (visualizzazione e traduzione in Java): il cammino attraverso l'AST inizia con un metodo di avvio per chiamate ricorsive sulle funzioni di inferenza di ciascun nodo, a partire dal let delle dichiarazioni globali di un modulo.

Come già accennato nella sezione 3.2, i metodi sono molto simili all'algoritmo \mathcal{W} mostrato, e le classi ausiliarie appena descritte facilitano lo sviluppo delle funzioni di inferenza seguendo tale modello da vicino.

Ciò nonostante, si vuol descrivere brevemente l'implementazione del metodo infer della classe Let, in quanto di particolare interesse per le modifiche apportate al fine di gestire opportunamente la ricorsione e la generalizzazione dei tipi delle funzioni.

L'inferenza per let, presentata nel Codice 5.11, si divide in 4 fasi:

- linee 3-21, inizializzazione del contesto:
 - creazione di una mappa per le posizioni delle dichiarazioni;
 - copia del contesto originale;
 - controllo di dichiarazioni duplicate;
 - aggiornamento del contesto con schemi di tipo temporanei;
- linee 23-43, inferenza sulle dichiarazioni locali:
 - initializzazione della sostituzione;
 - inferenza per ogni dichiarazione;
 - unificazione tra tipi noti (compresi quelli temporanei) e tipi inferiti, progressiva composizione delle sostituzioni;
 - applicazione della sostituzione al contesto;
- linee 45-53, generalizzazione dei tipi:
 - propagazione delle sostituzioni e chiamata alla funzione generalize;
 - controllo del tipo definito dallo sviluppatore;
 - aggiornamento del contesto;
- linee 55-60, inferenza sull'espressione principale:
 - chiamata ricorsiva;
 - composizione finale delle sostituzioni;
 - propagazione delle sostituzioni e assegnamento del tipo per il nodo let.

```
@Override
   public Utils.Tuple<Substitution, Type> infer(Context ctx) {
2
3
       // check for duplicate declarations within the same let
       Map<String, InputPosition> declarationPositions = new HashMap<>();
5
6
       Context newCtx = new Context(ctx);
7
      for (Declaration decl : localDeclarations.declarationList) {
8
9
          if (declarationPositions.containsKey(decl.id))
             InferenceEngine.reportError(decl.inputPosition,
10
                String.format("variable '%s' already declared at %s",
11
                   decl.id, declarationPositions.get(decl.id)));
12
         else (
13
14
             declarationPositions.put(decl.id, decl.inputPosition);
15
             // while also updating the context with placeholder schemes,
16
17
             // so that self and mutual recursion can be handled
             newCtx.bind(decl.id,
18
                new Scheme(Collections.emptySet(), InferenceEngine.newTypeVariable()));
19
         }
20
      }
21
22
       // proceed to infer all local declarations
23
       Substitution subst = Substitution.EMPTY;
24
25
       for (Declaration decl : localDeclarations.declarationList) {
26
         Utils.Tuple<Substitution, Type> declInference = decl.expression.infer(newCtx);
27
28
          try {
             // unifying types of known bindings,
29
30
             // gradually composing substitutions and updating context
             subst = subst.compose(declInference.fst())
31
                .compose(newCtx.bindingOf(decl.id).type
32
                   .applySubstitution(subst)
33
                   .unify(declInference.snd())); // could throw TypeException
34
35
             decl.expression.type = declInference.snd().applySubstitution(subst);
36
37
            newCtx = newCtx.applySubstitution(subst);
38
39
          } catch (TypeException e) {
             InferenceEngine.reportError(decl.inputPosition, e.getMessage());
40
41
             decl.expression.type = Type.Error.INSTANCE;
42
43
       }
44
       // finally generalize all types and check against actual user-defined schemes
45
46
       for (Declaration decl : localDeclarations.declarationList) {
47
         decl.expression.propagateSubstitution(subst);
48
49
         Scheme expectedScheme = decl.expression.type.generalize(newCtx);
         decl.checkScheme(expectedScheme);
50
51
         newCtx.bind(decl.id, decl.scheme());
52
      }
53
54
       // now it's possible to infer the expression type
55
      Utils.Tuple<Substitution, Type> exprInference = expression.infer(newCtx);
56
57
       subst = subst.compose(exprInference.fst());
58
       type = exprInference.snd().applySubstitution(subst);
59
60
       expression.propagateSubstitution(subst);
61
       return new Utils.Tuple<>(subst, type);
62
```

Codice 5.11: Metodo di inferenza per espressioni let

```
main = countdown 1825

countdown: Int -> Int
countdown = until (equalsEquals 0) (flip subtract 1)

until p f = until1

with
 until1 x = if p x then x else until1 (f x) fi

out
```

Codice 5.12: Esempio di inferenza

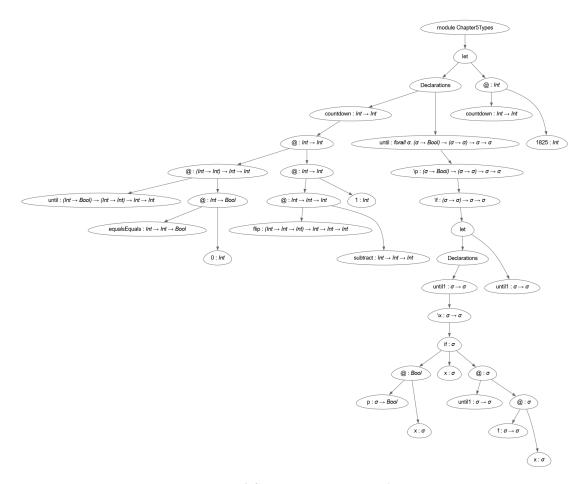


Figura 5.6: \mathbf{AST} con annotazioni di tipo

5.4 Traduzione in Java

La sottoclasse più importante di ASTVisitor è JavaTranspiler, il visitor che si occupa dell'ultimo stadio di compilazione, la traduzione dell'**AST** in codice Java: come per GraphvizBuilder, la classe compone una stringa che rappresenta il programma Java corrispondente al codice **Funx** sorgente.

Avendo già illustrato alcuni esempi di traduzione nel Capitolo 4, in questa sezione si discuteranno le scelte e i compromessi nel processo di traduzione, e il modo in cui le limitazioni di Java possano essere talvolta aggirate "piegando" le regole.

5.4.1 Membri statici

Il paradigma dichiarativo dei linguaggi funzionali è ben diverso dalla programmazione ad oggetti di molti altri linguaggi rinomati, motivo per cui la scelta di tradurre ogni programma **Funx** in un'unica classe statica è vista come semplice soluzione per evitare complicanze e *overhead* per la creazione di oggetti in aggiunta alle Function.

Ogni funzione definita diviene perciò una proprietà statica della classe in caso di monotipi (sezione 5.4.3) o un metodo statico con parametri di tipo in caso di politipi (sezione 5.4.4), eccezion fatta per le funzioni appartenenti a espressioni let annidate che, essendo classi anonime, creano un unico oggetto con proprietà e metodi privati (accessibili solamente al metodo pubblico eval della classe Let).

La traduzione inizia con import statici per la libreria standard e un costruttore privato.

```
1
    // append package, imports, class declaration and constructor
2
   builder.append(module.packageName.isEmpty()
3
          : String.format("package %s;%n", module.packageName.toLowerCase()))
4
       .append("\n\nimport ").append(Function.class.getName())
5
       .append(";\n\nimport ").append(JavaPrelude.class.getName())
6
       .append("; \n\nimport ").append(FunxPrelude.class.getName())
      .append(";\n\nimport static ").append(JavaPrelude.class.getName())
8
9
       .append(".*;\nimport static ").append(FunxPrelude.class.getName())
       .append(".*;\n\npublic class ").append(module.name).append(" {\n")
10
       .append("private ").append(module.name)
11
       .append("() {\n// private constructor to prevent instantiation\n}\n\n");
```

Codice 5.13: Prime aggiunte alla stringa Java

```
import java.util.function.Function;
1
2
   import com.github.massimopavoni.funx.lib.JavaPrelude;
3
4
    import com.github.massimopavoni.funx.lib.FunxPrelude;
6
7
   import static com.github.massimopavoni.funx.lib.JavaPrelude.*;
8
    import static com.github.massimopavoni.funx.lib.FunxPrelude.*;
10
   public class Chapter5Header {
11
      private Chapter5Header() {
         // private constructor to prevent instantiation
12
13
14
15
16
```

Codice 5.14: Corrispondente codice Java generato

5.4.2 Stack dei contesti

Durante l'esplorazione dell'**AST** è necessario tenere traccia dello *scope*, il contesto, del quale le dichiarazioni o i parametri lambda fanno parte: la soluzione adottata prevede l'uso di uno *stack* contenente i contesti attivi, rappresentati a loro volta da mappe con le variabili dichiarate come chiavi e le relative informazioni.

Lo *stack* dei contesti è in realtà implementato attraverso una lista per via della necessità di iterare su tutti i contesti e trovare una variabile richiesta (*lookup*).

```
private final List<Map<String, Utils.Tuple<Scheme, String>>>
1
2
      scopes = new ArrayList<>();
3
   private void addToScope(List<Declaration> declarations, String scope) {
4
      scopes.addFirst(declarations.stream()
         .collect(ImmutableMap.toImmutableMap(
6
7
            decl -> decl.id.
            decl -> new Utils.Tuple<>(decl.scheme(), scope))));
9
10
   private void addToScope(String id, Scheme scheme, String scope) {
11
12
      scopes.addFirst(Collections.singletonMap(id, new Utils.Tuple<>(scheme, scope)));
13
```

Codice 5.15: Struttura e metodi per lo scope

```
@Override
1
2
   public Void visitModule(ASTNode.Module module) {
       // add Prelude functions to the scope
3
       scopes.addFirst(Arrays.stream(PreludeFunction.values())
4
5
          .collect(ImmutableMap.toImmutableMap(
6
             pf -> pf.id,
             pf -> new Utils.Tuple<> (pf.scheme, pf.nativeJava
7
                ? JavaPrelude.class.getSimpleName()
9
                : FunxPrelude.class.getSimpleName()))));
       // add module functions to the scope
10
      addToScope(module.let.localDeclarations.declarationList, module.name);
11
12
13
       scopes.removeFirst();
14
       return null;
15
   }
16
   @Override
17
   public Void visitLambda(Expression.Lambda lambda) {
18
19
       // add lambda parameter to the scope
       addToScope(lambda.paramId, new Scheme(Collections.emptySet(),
20
21
          ((Type.FunctionApplication) lambda.type()).arguments.getFirst()), null);
       // ...
22
       scopes.removeFirst();
23
24
       return null;
25
   }
26
   @Override
27
   public Void visitLet(Expression.Let let) {
28
29
       currentLevel++;
       // add let local declarations to the scope
30
       addToScope(let.localDeclarations.declarationList, "this");
31
32
       // restore previous scope state and level
33
34
       scopes.removeFirst();
35
       currentLevel--;
       return null;
36
37
```

Codice 5.16: Aggiunta di contesto per modulo, lambda astrazioni e let

Nei Codici 5.15 e 5.16 sono mostrate:

- la lista dei contesti e le funzioni per la loro gestione: le tuple assegnate ai nomi delle dichiarazioni di uno *scope* conservano lo schema di tipo e il nome della classe statica in cui la variabile è definita (JavaPrelude, FunxPrelude, nome del modulo creato, null per parametri lambda e this per i let);
- l'aggiunta dei contesti per Module, Lambda e Let, rispettivamente: funzioni di libreria e dichiarazioni del modulo stesso, parametro lambda e dichiarazioni locali con l'incremento del livello di annidamento.

5.4.3 Dichiarazioni monomorfe

La possibilità in **Funx** di utilizzare funzioni ricorsive e mutuamente ricorsive e la volontà di evitare la traduzione di ogni dichiarazione in un metodo sono in conflitto a causa di *Illegal Self Reference* e *Illegal Forward Reference*: tali errori si presentano durante la compilazione del codice Java qualora i campi statici che identificano funzioni monomorfe vengano dichiarati e inizializzati nello stesso *statement* (stessa linea).

La dichiarazione delle proprietà deve avvenire prima di poter apparire nell'inizializzazione di altre variabili; si potrebbe effettuare un'analisi iniziale dell'**AST** per identificare le dipendenze tra le funzioni (approccio di ordinamento topologico estremamente utile anche per l'inferenza), ma la soluzione adottata è di più semplice implementazione.

Come si può notare nel Codice 5.17 e in alcuni esempi già presentati in precedenza, si effettua la dichiarazione di ogni campo, pubblico e statico per le dichiarazioni globali, privato per quelle locali, e solo successivamente si inizializzano rispettivamente con blocco statico e metodo eval.

```
public class Chapter5Monomorphic {
1
2
       private Chapter5Monomorphic() {
3
          // private constructor to prevent instantiation
4
       public static void main(String[] args) {
6
          System.out.println(add.apply(add.apply(fun1).apply(fun2)).apply(letFun));
7
9
10
       public static Long fun1;
       public static Long fun2;
11
       public static Long letFun;
12
13
       static {
14
15
          fun1 = 1L;
          fun2 = 2L;
16
          letFun =
17
             (new Let<>() {
18
19
                private Long a:
                private Long b;
20
21
22
                @Override
23
                public Long _eval() {
24
                    a = 3L;
                    b = 4L;
25
26
                    return add.apply(a).apply(b);
27
             })._eval();
28
29
    }
30
```

Codice 5.17: Traduzione di funzioni monomorfe

Poiché potrebbero essere presenti diversi let annidati, è necessario tenere traccia delle espressioni corpo delle dichiarazioni monomorfe in modo da poterle inizializzare al momento corretto, dopo aver tradotto ulteriori classi interne.

La procedura di traduzione di dichiarazioni monomorfe si compone delle seguenti fasi:

- definizione di uno *stack* contenente mappe tra nomi delle dichiarazioni e nodi espressione corrispondenti;
- inserimento di una nuova mappa per il livello corrente di annidamento (modulo o espressione let);
- inferenza delle funzioni globali o locali con dichiarazione delle variabili e aggiunta delle espressioni monomorfe alla mappa corrente (potrebbero essere aggiunti nuovi livelli prima di poterne "riempire" uno);
- creazione del blocco statico (o metodo eval per le espressioni let) con le inizializzazioni delle funzioni con monotipo: in questa fase finale torna utile la versatilità del *visitor pattern* per posticipare la traduzione delle espressioni.

```
private final Deque<Map<String, Expression>>
1
2
      monomorphicDeclarationsQueue = new ArrayDeque<> ();
3
   public Void visitLet(Expression.Let let) {
5
      currentLevel++;
6
      // ...
      // use a new anonymous class for the let expression
8
9
       // and push a new monomorphic let declarations map
      builder.append("(new ")
10
             .append(JavaPrelude.Let.class.getSimpleName()).append("<>() {\n");
11
      monomorphicDeclarationsQueue.push(new LinkedHashMap<>());
12
      visit(let.localDeclarations);
13
      builder.append("""
14
15
                   @Override
                   public\s""")
16
17
             .append(typeStringOf(let.expression.type()))
18
             .append("\n_eval() {\n");
      // if there are any monomorphic declarations, initialize them in the _eval method,
19
       // then pop the map either way
20
      if (!monomorphicDeclarationsQueue.getFirst().isEmpty())
21
22
          monomorphicDeclarationsQueue.getFirst().forEach((id, expression) -> {
             builder.append(id).append(" = ");
             visit(expression); // deferred expression visit
24
25
             appendSemiColon();
             appendNewline();
26
         });
27
      monomorphicDeclarationsQueue.pop();
28
29
30
      currentLevel--;
      return null;
31
32
```

Codice 5.18: Traduzione di funzioni monomorfe in let

```
@Override
2
   public Void visitDeclaration(Declaration declaration)
      // top level declarations should be static and public,
3
       // while let local declarations should be private to the anonymous class
      builder.append(currentLevel == 0 ? "public static " : "private ");
5
      String scheme = schemeStringOf(declaration.scheme());
6
7
       if (declaration.scheme().variables.isEmpty()) {
          // defer initialization of monomorphic declarations
8
9
         builder.append(scheme).append(" ").append(declaration.id);
         appendSemiColon();
10
         monomorphicDeclarationsQueue
11
             .getFirst().put(declaration.id, declaration.expression);
12
13
          // initialize polymorphic declarations immediately (as methods with generics)
14
15
         builder.append(scheme)
                .append(" ").append(declaration.id).append("() {\nreturn ");
16
17
         visit(declaration.expression);
         appendSemiColon();
18
         appendCloseBrace():
19
20
       appendNewline();
21
22
       return null;
```

Codice 5.19: Metodo visit per le dichiarazioni

5.4.4 Istanziazione di funzioni polimorfe

Dal momento che il contesto può cambiare con l'introduzione di parametri lambda oltre che con espressioni let, il livello di annidamento di quest'ultime è segnalato da una variabile secondaria utilizzata durante il *lookup* delle variabili per verificare se è possibile istanziare una funzione polimorfa in modo naturale e idiomatico per Java.

Tale variabile (currentLevel) è stata introdotta nei precedenti estratti di codice del JavaTranspiler, ma se ne fa maggior uso nel caso di funzioni polimorfe per specificare i parametri di tipo quando possibile.

Visitando un nodo Variable dell'albero sintattico astratto si incontrano tre casi:

- 1. funzione monomorfa o parametro lambda (tutte le variabili introdotte da una lambda astrazione possiedono un monotipo per via del polimorfismo di rango 1);
- 2. funzione polimorfa proveniente da uno *scope* compreso tra quello globale e il livello di annidamento corrente; opzione rappresentante uno dei casi limite già menzionati, causato dall'impossibilità di fare riferimento esplicito ad un membro di una classe anonima esterna; la soluzione è utilizzare il metodo definito in JavaPrelude per istanziare la funzione parametrica tramite un *cast*;
- 3. funzione polimorfa proveniente dal livello di annidamento attivo, livello globale (scope con stesso nome del modulo) o libreria standard; in questa alternativa è possibile unificare un'istanza dello schema di tipo con il tipo della variabile nell'espressione considerata e quindi parametrizzare la chiamata.

```
@Override
2
   public Void visitVariable(Expression.Variable variable) {
3
       // firstly, find the variable in the scopes
      Utils.Tuple@<Scheme, String@> variableScheme = null;
5
6
       for (i = 0; i <scopes.size(); i++)</pre>
          if ((variableScheme = scopes.get(i).get(variable.id)) != null)
7
8
9
       // cannot have a null tuple, since type inference would have failed before this
10
       if (Objects.requireNonNull(variableScheme).fst().variables.isEmpty())
11
          // 1 -> lambda param or monomorphic declaration
12
          builder.append(variable.id);
13
14
15
       else if (variableScheme.snd().equals("this") && i >0 && i <currentLevel)
         // 2 -> polymorphic declaration from an intermediate let scope
16
17
          // needs the worst: an unchecked cast
          builder.append(JavaPrelude.class.getSimpleName()).append(".<")</pre>
18
             .append(typeStringOf(variable.type())).append(">_instantiationCast(")
19
20
             .append(variable.id)
             .append("())");
21
22
23
          // 3 -> polymorphic declaration from Prelude,
24
25
          // top level or same let scope can properly use generics
26
          builder.append(variableScheme.snd()).append(".<");</pre>
27
28
             // to do so we need to instantiate the scheme and find the substitution
             Utils.Tuple@<Substitution, Type@> instantiation =
29
30
                variableScheme.fst().instantiate();
31
             Substitution subst = instantiation.fst()
32
                .applySubstitution(instantiation.snd().unify(variable.type()));
33
34
             // to then apply to the sorted variables
35
             builder.append(variableScheme.fst().sortedVariables.stream()
36
                   .map(ov @@-> subst.variables().contains(ov)
37
38
                       ? typeStringOf(subst.substituteOf(ov))
39
                       : Type.Variable.toString(ov))
                   .collect(Collectors.joining(", ")))
40
41
                .append(">").append(variable.id).append("()");
          } catch (TypeException e) {
42
43
             // should never happen
44
             throw new InferenceException(e.getMessage());
45
46
47
       return null;
48
```

Codice 5.20: Metodo visit per le variabili

```
// Cast method for polymorphic functions instantiation

@SuppressWarnings("rawtypes, unchecked")

public static @<T extends Function@> T _instantiationCast(Function f) {
    return (T) f;
}
```

Codice 5.21: Metodo di istanziazione con cast

Nei Codici 5.22 e 5.23 si può osservare come il procedimento descritto produca variabili usate semplicemente, istanziate tramite *cast* o con parametri di tipo.

Codice 5.22: Let annidati e differente uso di variabili polimorfe

```
public class Chapter5Nested {
1
2
      private Chapter5Nested() {
          // private constructor to prevent instantiation
3
4
5
      public static <h> Function<h, h> multipleIds() {
6
7
          return (x ->
8
             (new Let<>() {
                private <d> Function<d, d> id1() {
9
10
                   return FunxPrelude.<d>id(); // 3
11
12
                @Override
13
                public h _eval() {
14
                   return (new Let<>() {
15
                      private <f> Function<f, f> id2() {
16
17
                          return JavaPrelude
18
                             .<Function<f, f>>_instantiationCast(id1()); // 2
19
                      }
20
21
                      @Override
                      public h _eval() {
22
                         return this.<h>id2().apply(x); // 3 and 1
23
24
25
                   })._eval();
26
27
             })._eval());
28
```

Codice 5.23: Corrispondente traduzione in Java

5.4.5 Type casting "selvaggio"

L'ultima particolarità della traduzione riguarda una stranezza occasionalmente necessaria quando l'applicazione di una funzione ad un'espressione più complessa richiede un ulteriore *cast*: questi cast sono non sempre necessari ma prevederne l'esigenza a priori è difficile ed è il motivo per cui sono stati battezzati "selvaggi" (*wild cast*).

L'implementazione dei wild cast è data da una flag booleana abilitata in un nodo Application qualora le espressioni coinvolte siano oggetti Lambda o Let, mentre il cast è applicato nei metodi visit interessati.

```
@Override
1
2
   public Void visitApplication(Expression.Application application) {
3
      // left and right expressions necessitate a wild cast
      // if they are lambda or let expressions
4
      if (application.left instanceof Expression.Lambda
5
             || application.left instanceof Expression.Let)
6
7
          wildCast = true;
      visit(application.left);
8
9
      builder.append(".apply(");
10
11
      if (application.right instanceof Expression.Lambda
             || application.right instanceof Expression.Let)
12
          wildCast = true;
13
      visit(application.right);
14
15
      builder.append(")");
      return null;
16
17
```

Codice 5.24: Metodo visit per le applicazioni di funzione

```
@Override
   public Void visitLambda(Expression.Lambda lambda) {
2
3
4
       if (wildCast) {
          // wild cast is needed for lambdas in applications
5
6
          builder.append("(").append(typeStringOf(lambda.type())).append(") ");
7
          wildCast = false;
8
9
       return null;
10
11
12
13
   @Override
14
    public Void visitLet(Expression.Let let) {
15
       if (wildCast) {
16
          // wild cast is needed for lets in applications
17
          builder.append("(").append(typeStringOf(let.type())).append(") ");
18
19
          wildCast = false;
20
       // ...
21
22
       return null;
23
```

Codice 5.25: Wild cast in espressioni lambda e let

Nei Codici 5.26 e 5.27 si nota come i *cast* rendano la traduzione ancora meno leggibile, ma si può facilmente verificare che la compilazione fallisce se alcuni *cast* sono rimossi (*cast* di destra in reverseApply e *cast* di sinistra in anonymousIds).

Codice 5.26: Applicazione tra funzioni, espressioni let e lambda

```
public class Chapter5Wild {
1
2
      private Chapter5Wild() {
3
        // private constructor to prevent instantiation
4
      public static <j, k> Function<j, Function<function<j, k>, k>> reverseApply() {
6
         return FunxPrelude.<Function<j, k>, j, k>flip()
7
           .apply(
               (Function<Function<j, k>, Function<j, k>>) // right wild cast
9
10
                 (new Let<>() {
                    private <h, i> Function<Function<h, i>, Function<h, i>> apply1() {
11
                       return (f -> (x -> f.apply(x)));
12
13
14
                    @Override
15
16
                    public Function<Function<j, k>, Function<j, k>> _eval() {
                       return this.<j, k>apply1();
17
18
19
                 })._eval());
20
^{21}
      public static <n> Function<n, n> anonymousIds() {
22
         23
24
           .apply(((Function<n, n>) x \rightarrow x)); // right wild cast
25
      }
26
```

Codice 5.27: Traduzione in Java con cast "selvaggi"

6. Conclusioni

Bibliografia

- [Bar91] Henk Barendregt. «Introduction to generalized type systems». In: *Journal of Functional Programming* 1.2 (apr. 1991), pp. 125–154. DOI: 10.1017/s0956796800020025.
- [Chu32] Alonzo Church. «A Set of Postulates for the Fundation of Logic». In: *Annals of Mathematics* 33.2 (apr. 1932), pp. 346–366. DOI: 10.2307/1968337.
- [Chu33] Alonzo Church. «A Set of Postulates for the Foundation of Logic». In: *Annals of Mathematics* 34.4 (ott. 1933). Second paper, pp. 839–864. DOI: 10.2307/1968702.
- [Clé+86] Dominique Clément et al. «A Simple Applicative Language: Mini-ML». In: Proceedings of the 1986 ACM conference on LISP and functional programming - LFP '86 (8 ago. 1986), pp. 13–27. DOI: 10.1145/319838.319847.
- [DM82] Luis Damas e Robin Milner. «Principal type-schemes for functional programs». In: Proceedings of the 9th ACM SIGPLAN-SIGACT symposium on Principles of programming languages POPL '82 (25 gen. 1982), pp. 207—212. DOI: 10.1145/582153.582176.
- [Eis15] Richard A. Eisenberg. «System FC, as implemented in GHC». In: (2015). Last updated in 2020. URL: https://github.com/ghc/ghc/blob/master/docs/core-spec/core-spec.pdf?raw=true.
- [Gra06] Martin Grabmüller. «Algorithm W Step by Step». In: (26 set. 2006). URL: https://github.com/mgrabmueller/AlgorithmW/blob/master/pdf/AlgorithmW.pdf?raw=true.
- [Hin69] J. Roger Hindley. «The Principal Type-Scheme of an Object in Combinatory Logic». In: *Transactions of the American Mathematical Society* 146 (dic. 1969), pp. 29–60. DOI: 10.2307/1995158.
- [LY98] Oukseh Lee e Kwangkeun Yi. «Proofs about a Folklore Let-Polymorphic Type Inference Algorithm». In: *ACM Transactions on Programming Languages and Systems (TOPLAS)* 20.4 (1 lug. 1998), pp. 707–723. DOI: 10.1145/291891.291892.
- [Mil78] Robin Milner. «A Theory of Type Polymorphism in Programming». In: Journal of Computer and System Sciences 17.3 (dic. 1978), pp. 348–375. DOI: 10.1016/0022-0000 (78) 90014-4.
- [Mog91] Eugenio Moggi. «Notions of Computation and Monads». In: *Information and Computation* 93.1 (lug. 1991), pp. 55–92. DOI: 10.1016/0890-5401 (91) 90052-4.
- [Par13] Terence J. Parr. *The Definitive ANTLR 4 Reference*. Pragmatic Bookshelf, 22 gen. 2013. ISBN: 978-1-934356-99-9.

- [PF11] Terence J. Parr e Kathleen Fisher. «LL(*): the foundation of the ANTLR parser generator». In: Proceedings of the 32nd ACM SIGPLAN Conference on Programming Language Design and Implementation PLDI '11 (4 giu. 2011), pp. 425–436. DOI: 10.1145/1993498.1993548.
- [PHF14] Terence J. Parr, Sam Harwell e Kathleen Fisher. «Adaptive LL(*) parsing: the power of dynamic analysis». In: Proceedings of the 2014 ACM International Conference on Object Oriented Programming Systems Languages and Applications OOPSLA '14 (15 ott. 2014), pp. 579–598. DOI: 10.1145/2660193.2660202.
- [PQ95] Terence J. Parr e Russell W. Quong. «ANTLR: A predicated-LL(k) parser generator». In: Software: Practice and Experience 25.7 (lug. 1995), pp. 789–810. DOI: 10.1002/spe.4380250705.
- [Wel99] Joe B. Wells. «Typability and type checking in System F are equivalent and undecidable». In: *Annals of Pure and Applied Logic* 98.1-3 (30 giu. 1999), pp. 111–156. DOI: 10.1016/s0168-0072 (98) 00047-5.

Ringraziamenti